

AI 应用产品经理 面试准备

汪非凡 | 提纲与口语回答版

64 道主问题 · 129 道追问

每题都有记忆提纲，每个追问都有答题思路。

先给判断，再讲依据。

产品面试不是罗列术语。讲清用户为什么需要、方案为什么这样选、结果用什么验证，让经历体现你的判断与贡献。

本版重点：业务取舍 / 技术边界 / 效果验证 / HR 表达

更新：2026 年 9 月 9 日 | 上一版保留

阅读导航

阅读前 | 这次怎么改，怎么记

3

一 | 岗位匹配：让面试官听清你能带来什么（Q01—Q08）

4

二 | 个人项目：把产品决策讲具体（Q09—Q25）

9

三 | 企业项目：体现需求分析和交付判断（Q26—Q33）

18

四 | AI 基础：回答选型、边界与验证（Q34—Q43）

23

五 | 场景题：给出决策，不只列分析框架（Q44—Q50）

28

六 | 实现深挖：把技术说到产品价值上（Q51—Q56）

32

七 | HR 与入职：诚实，但不要把答案说成自我否定（Q57—Q64）

36

附录 | 记忆卡、事实边界与参考来源

41

目录可点击；侧边书签可直接定位全部 64 道题。绿色框是主问题的记忆提纲，灰色短句是追问思路。

阅读前 | 这次怎么改，怎么记

本版重新组织答案：先回答面试官真正要判断的事，再解释选择，最后用经历或例子证明。保留 Q01—Q64 编号；129 道追问同样重写并附思路，不只是给旧答案加标题。

每题顺序：考察点 → 记忆提纲 → 口语回答 → 追问思路与回答。先记提纲，再脱稿讲，不背整段文字。普通题约 45—75 秒，项目介绍可讲 90—120 秒；短答讲完就停，等对方继续问再展开。

上一版的问题：只说“看需求、看指标”，没有讲清判断标准；把核准提醒放进了口述；技术题偏名词解释，缺少选型和业务取舍；部分追问没有正面回答。本版将这些分别改为具体决策、独立备注、项目例子和直接作答。

事实口径集中在这里，不必每题主动念：保融任职 2023.11.14—2026.03.31，含毕业前实习，宣称“两年多企业项目经历”；豪森是跨模块需求的澄清、设计、开发联调，不是独立负责整个客户项目。媒介助手最后确认仍在备案、准备上线；一天名单自测不是线上用户平均效果；没有确认的注册、付费和审核提效数据不补写。

方法题中的“我会”是处理思路，不等于曾实施；经历题中的“我做过的”取自己确认材料。RAG、受控检索循环与 Eval 延用 9 月 7 日核对的实现边界，本轮不重新运行生产验收。少数待填事实以 [填写] 标出。备考备注不属于口述答案。

一 | 岗位匹配：让面试官听清你能带来什么（Q01—Q08）

Q01 | 请做一下自我介绍

考察点：与岗位的关联，以及两件值得继续深挖的事。

记忆提纲：① 两年多企业交付 ② 豪森复杂需求 ③ 媒介助手独立实践 ④ 应聘 AI 应用产品

口语回答：您好，我叫汪非凡，江西理工大学软件工程本科毕业。之前在保融做全栈开发，有两年多含实习的企业项目经历，服务过吉利、厦门国贸、豪森药业等客户。我比较突出的能力，是把不清楚的业务要求拆成能交付的方案。比如豪森的一项资金计划需求，我参与了需求澄清、跨模块流程和异常规则设计，并完成开发联调，功能已投入运行。后来我独立做了媒介助手，解决找达人和图文初审的问题，从调研、原型到开发测试都自己推进。现在希望做 AI 应用产品，把业务分析和技术落地结合起来，对功能有没有真正帮到用户负责。

追问1：为什么现在转产品？

追问提纲：长期兴趣 → 实践验证

以前做开发，我就会往前追问需求为什么这么定。独立做媒介助手后，我发现自己更愿意花时间判断用户该先解决哪个问题、方案怎么取舍，所以这次不是只换个职位名称，而是希望把这些工作变成主要职责。

追问2：项目用了哪些 AI？

追问提纲：理解需求 → 判断内容 → 规则托底

主要用在自然语言需求解析、达人内容的语义匹配和图文审核。粉丝区间、去重和状态更新仍由代码处理。我的考虑是，把表达多变、需要理解的部分交给模型，把必须准确执行的部分留在系统里。

追问3：豪森是你一个人做的吗？

追问提纲：限定范围 → 说明贡献

不是整个项目。我负责较深的是验收末期的一项跨模块需求，承担澄清、流程与异常设计、开发和联调；业务规则由客户及产品、项目负责人确认，测试和实施也有各自职责。

Q02 | 为什么从开发转 AI 产品经理？

考察点：是逃离开发，还是理解产品职责后做出的选择。

记忆提纲：① 关注问题定义 ② 两段经历验证 ③ 技术成为优势 ④ 接受结果责任

口语回答：我想转的核心原因，是希望从“把需求实现出来”，往前走到“决定应该解决什么问题”。在企业项目里，我发现很多返工并不是代码难，而是业务口径和异常条件没有讲清。做媒介助手时，我又要自己决定先做找人还是审核、哪些判断用模型、什么时候让人确认。这些取舍比单纯实现功能更吸引我。开发经验能帮助我判断成本和可行性，但做产品以后，不能只以按期交付为终点，还要看用户是否采用、有没有减少工作量。这是我想承担的责任变化。

追问1：能接受大量琐碎协调吗？

追问提纲：理解职责 → 举原有协作

能。以前就需要跟产品、测试、实施和客户反复对口径。产品协调的价值，是让关键问题有人决策、各方对交付有相同预期，不是开完会就结束。我对这部分工作有实际接触。

追问2：为什么不做技术产品经理？

追问提纲：不排斥名称 → 看实际责任

如果是企业 AI 工具、流程自动化，我也接受技术产品经理的定位。我更看重是否能负责用户需求、方案和效果，而不是只维护接口文档或被动接开发任务。

Q03 | 为什么选 AI 应用，而不是模型或算法平台？

考察点：能否清楚选择方向，不把 AI 岗位混为一谈。

记忆提纲：① 从业务任务切入 ② 企业流程优势 ③ 模型能力产品化 ④ 明确非训练背景

口语回答：AI 应用更能发挥我的现有优势。我接触过企业里的流程、权限和异常，也能把方案做出来，这有助于把模型接进一项具体工作。模型或训练平台需要更深的算法、训练和算力经验，不是我目前积累最强的部分。我更想解决的是：模型能力看起来不错，怎样接入数据和工具、设计确认环节，再通过评测变成可用的功能。企业助手、内容效率工具和业务流程辅助，都是我愿意深入的方向。

追问1：哪些岗位不适合你？

追问提纲：能力匹配 → 不按行业一刀切

以预训练、训练平台或算法研究为核心，要求直接经验的岗位，目前不适合我。行业上我比较开放，优先判断它是否有清楚的用户任务，以及企业交付经验能否迁移过去。

追问2：怎么补算法基础？

追问提纲：实际错误 → 对应原理 → 实验验证

沿项目问题补。例如匹配不准，先分清没召回还是排序差，再学习相应检索方法；图片漏看则检查输入质量和视觉能力。学完要能解释错误、设计对照实验，而不只是复述概念。

Q04 | 为什么录用你，而不是有正式产品经验的人？

考察点：差异化价值，而不是证明所有方面都胜过别人。

记忆提纲：① 复杂业务拆解 ② 技术可行性判断 ③ 独立推进 ④ 匹配具体模块

口语回答：如果岗位需要一个能理解企业业务、跟研发把方案落下去的人，我有比较直接的优势。豪森的经历说明，我能把付款、额度和异常处理这种跨模块需求理清；开发背景让我讨论方案时能提前看到数据依赖、实现成本和风险；媒介助手则证明我能独立从用户问题推进到原型和功能验证。这不能完全替代成熟产品经验，但对需要快速验证 AI 场景、独立负责具体模块的团队，我能较快进入工作，也有真实材料供您判断。

追问1：提前发现过什么技术风险？

追问提纲：最关键依赖 → 先验证再扩建

找达人功能最关键的依赖是真实数据能不能取得。因此项目先验证搜索和主页读取，而不是先做完整管理界面。这个依赖不成立，后面的体验再好也没有价值，产品范围就要及时调整。

追问2：产品基本功怎么证明？

追问提纲：一条需求 → 流程原型 → 验收一致

可以拿媒介助手的一条需求现场展开：原来怎么做、最耗时在哪里、为什么这样设计、失败后怎么继续，再对应到原型和验收。能把这几件事讲一致，比只说熟悉 PRD、Figma 更有说服力。

Q05 | 你最大的短板是什么？

考察点：认识真实差距，并有可执行的补足方式。

记忆提纲：① 缺持续运营经验 ② 已有交付基础 ③ 用真实任务补齐 ④ 形成指标习惯

口语回答：我最需要补的是上线后的持续产品经营经验。过去企业项目更关注交付和规则正确，个人项目也还在上线准备，用户留存、付费和长期效果不是我已经做成熟的部分。补这个短板，我会从具体功能开始，先定义用户完成什么任务、留下哪些数据，再跟踪第一次是否做成、为什么修改、下次是否还用。我希望把需求、交付和效果接起来，不一直用“技术背景”解释优势，而是尽快积累真实的产品结果。

追问1：一个月拿不到足够用户数据怎么办？

追问提纲：少量深访 → 真实任务 → 限定结论

先做任务观察，不必等大样本。让目标用户用自己的需求完成工作，记录卡点、修改和采用情况。这能发现可用性问题，但不足以证明普遍提效，结论按样本范围说。

追问2：除了数据，还有什么不足？

追问提纲：商业取舍 → 显式比较成本收益

商业优先级还需要更多实践。以前习惯先解决“怎么做”，现在要先判断值不值得做。我会把覆盖的用户、影响的工作、投入和验证方法写进需求，避免只按实现难度排期。

Q06 | 怎么理解 AI 产品经理？

考察点：理解 AI 的不确定性和新增产品责任。

记忆提纲：① 选有价值的任务 ② 设计人机分工 ③ 定义质量与成本 ④ 持续验证

口语回答：AI 产品经理首先还是解决用户问题，但要多负责一层：模型输出不是每次都稳定，产品怎么接住这种不确定性。比如图文审核，不只是调用模型给一个结论，还要决定哪些规则必须检查、依据不足怎么办、什么情况交给人工，以及等待和费用能否接受。所以我会重点做好场景选择、人机分工和效果评估。最终标准不是用了多复杂的 Agent，而是用户在可接受的风险和成本下，能不能更好地完成工作。

追问1：传统产品经理最该补哪三项？

追问提纲：能力边界 → 数据组织 → 评测

模型擅长什么、哪里容易错；资料、工具和上下文怎样影响结果；怎样设计评测。否则很容易把演示效果当稳定能力，也很难跟研发讨论问题出在哪。

追问2：必须会写代码吗？

追问提纲：不必独立开发 → 必须能判断

不一定要能独立开发，但要理解接口、数据流和失败原因，能跟研发验证方案。会代码是我的加分项，但产品价值仍是选择问题、组织方案和验证结果，不能按代码量衡量。

Q07 | AI 应用和 Agent 有什么区别？

考察点：概念清楚，知道何时需要自主执行。

记忆提纲：① 产品与执行方式 ② 固定流程也能做 AI ③ Agent 动态选行动 ④ 自主性有成本

口语回答：AI 应用是在说产品用 AI 解决什么问题，Agent 是完成任务的一种执行方式。比如固定步骤分析 JD、改简历，就是 AI 应用，不一定需要 Agent。若系统拿到搜索结果后，要判断下一步查什么、调哪个工具、什么时候结束，就更适合 Agent。它的价值是处理路径不固定的任务，代价是更难控制成本和错误。我不会默认应用都要做成 Agent，而是看动态决策能否带来实际收益。〔来源1〕

追问1：媒介助手属于哪种？

追问提纲：整体是应用 → 模块不同自主度

整体是 AI 应用。审核更适合固定阶段的 Workflow；找达人有按结果继续检索或结束的循环。目前不少动作由代码策略控制，模型做意图和内容理解，是受控执行，不是全程自主规划。

追问2：什么场景不用 Agent？

追问提纲：路径明确 → 错误代价高 → 规则先行

固定字段提取、报表汇总、按明确规则校验，通常先用固定流程。付款这类高风险动作，也不能因为模型说要执行就直接执行，必须有确定的权限、业务校验和确认环节。

Q08 | 未来三年怎么规划？

考察点：方向与岗位一致，有现实的成长路径。

记忆提纲：① 先负责模块 ② 再负责完整场景 ③ 建立业务与评测能力

口语回答：先成为能独立负责 AI 功能的产品经理，把需求、方案、研发推进和上线反馈完整做下来。之后希望在一个业务领域持续积累，能够判断哪些场景值得做、投入怎么分配，而不是每次从概念开始。再往后争取负责更完整的产品方向，兼顾效果、成本和商业结果。我不急着追管理头衔，更想先有一段经得起复盘的产品成绩。

追问1：为什么上海？

追问提纲：城市选择明确 → 与岗位方向结合

上海是我这次明确的求职城市。我会重点找企业 AI 应用和效率工具团队，希望发挥原来的企业项目经验，也希望在一个城市持续积累，不跟着短期热点频繁换方向。

追问2：大厂和创业公司怎么选？

追问提纲：优先中大厂 → 看真实职责

目前优先中大型公司，想在成熟协作环境里把产品基本功补扎实。但最终也看岗位：有没有真实用户、能否负责完整模块、评价标准是否清楚。只有公司名气、实际工作不匹配，也会慎重。

二 | 个人项目：把产品决策讲具体（Q09—Q25）

Q09 | 用两分钟介绍媒介助手

考察点：讲清用户、问题、关键方案和结果，不罗列功能。

记忆提纲：① 逐个找人和查证很慢 ② 筛选与审核两项任务 ③ AI 理解、规则执行、人复核 ④ 自测与下一步

口语回答：媒介助手是我从朋友的实际工作里发现的机会。她做素人投放，需要搜关键词、逐个看主页和内容，再整理名单；图文宣传表达还要另行检查。问题不只是搜索慢，而是重复筛选和查证占用了时间。我把产品分成两块：找达人时，先把自然语言需求转成条件，代码处理粉丝范围和去重，模型辅助判断内容是否匹配，再进入候选管理；审核时，把图文、规则依据和风险位置放在一起，给修改建议，最终由人确认。我独立推进了调研、需求、Figma 原型、开发和测试。在一天自测里，20 人名单从约 3 小时缩短到 40—60 分钟。目前还在备案、准备上线，下一步重点看真实媒介采用率，以及审核是否减少复核工作量。

追问1：41 人能说明什么？

追问提纲：技术验收 → 不是用户成果

那是历史验收里真实落库的达人数量，说明检索、保存、展示和导出链路跑通。它不是注册人数，也不能直接证明候选质量。业务价值要看有多少人被媒介认为值得进一步沟通。

追问2：一人项目如何证明协作？

追问提纲：独立推进与团队协作分开举证

这个项目主要证明我能独立做取舍、推进到底。团队协作用保融经历说明：从产品澄清到测试联调、实施上线，再到驻场客户沟通，这些是在多人交付环境里实际做过的。

Q10 | 如何发现和验证需求？

考察点：把一句抱怨转成可验证的用户问题。

记忆提纲：① 还原真实任务 ② 找耗时和返工 ③ 确认可用标准 ④ 用任务验证

口语回答：我会先看用户最近完成的一次任务，而不是直接问想要什么功能。媒介说找人慢，要拆出时间花在想关键词、看主页、判断匹配还是整理名单；再问哪些候选最后会被淘汰，达到什么标准才能交出去。这样才能判断 AI 该介入哪一步。媒介助手的起点是朋友的真实需求，之后更重要的验证是让同类用户带自己的任务来试，看总耗时、采用和返工，而不是只问界面喜不喜欢。

追问1：访谈问了什么？

追问提纲：最近一次 → 淘汰理由 → 交付标准

已经确认的是她通过关键词搜索、逐个进入主页筛选，很耗时间。继续深挖时，我会围绕“最近一份名单怎么做出来”“为什么排除某个人”“交给同事后还重做什么”来问，比泛泛问想要哪些 AI 功能更有效。

追问2：其他媒介流程不同怎么办？

追问提纲：任务分群 → 先服务一类

先看是否属于不同群体。个人媒介重视快速初筛，机构团队可能还需要审批和多人协作。第一版先做好一个群体的核心任务，共用标准流程，少量差异用可配置条件，不直接做成大平台。

Q11 | 核心问题和北极星指标是什么？

考察点：分清价值规模、任务质量和诊断指标。

记忆提纲：① 交出可用名单 ② 北极星看价值产出 ③ 完成率解释质量 ④ 审核分开衡量

口语回答：核心价值是让媒介更省力地交出可用名单。稳定使用后，我会把“每周被用户确认可用于下一步沟通的名单任务数”作为北极星候选，因为它包含使用量和被认可的价值。名单任务完成率、总耗时、候选采用率用来解释它为什么变化。当前冷启动阶段，先验证单次任务有没有价值，比追总量更重要。审核是另一类任务，要单独看有效初审和人工复核成本，不能把两类产出简单相加。

追问1：为什么不用 DAU？

追问提纲：非每日任务 → 登录不等于价值

媒介不一定每天建名单，登录也可能只是看一眼。DAU 能观察活跃，但不能代表工作完成。北极星更应该贴近被认可的交付，同时要固定任务粒度，防止把一件事拆成很多任务来做高数量。

追问2：有效候选怎么定义？

追问提纲：硬条件合格 → 业务愿意推进

先满足事先确认的粉丝、主题等必要条件，再由媒介判断是否值得联系。系统高分只是筛选信号，不直接等于有效，更不等于合作。统计时要把候选、采用和合作分开。

Q12 | 如何确定 MVP 和优先级？

考察点：围绕关键假设缩范围，不是机械减少功能。

记忆提纲：① 最大不确定性 ② 最小完整任务 ③ 安全底线保留 ④ 非核心后置

口语回答：MVP 要用最小投入验证产品是否成立。媒介助手有两个关键假设：真实数据能取得，筛出来的人值得用。所以先验证数据链路，再围绕解析条件、检索筛选、人工确认、保存导出做一条完整路径。团队权限、多平台和复杂运营后置，但必要的用户隔离和失败恢复不能省。审核可以独立验证，不能因为与媒介相关就无限扩大首版范围；资源紧时先证明找人这一项价值。

追问1：为什么审核也进入 MVP？

追问提纲：另一具体任务 → 承认范围取舍

它也是媒介工作中的问题，而且可以独立使用。但同一群用户，不代表两项任务都值得首版做。复盘看范围偏宽；更合理的是先验证找人，审核用小样本单独测试，再决定是否正式合并。

追问2：只给一周砍什么？

追问提纲：保完整任务 → 削管理复杂度

保留真实数据、核心条件、结果解释、人工选人和导出，不做复杂分组、团队权限和商业化。审核先做受控验证。这样一周后至少能判断一项任务有没有价值。

Q13 | 为什么自然语言输入，不用传统表单？

考察点：按输入特性选择交互，不为了 AI 化改入口。

记忆提纲：① 复杂表达用文本 ② 精确约束用控件 ③ 执行前确认 ④ 混合输入

口语回答：自然语言不应该完全替代表单。媒介需求既有粉丝范围，也有“像真实分享、不要机构感”这种难枚举的描述。自然语言适合后者，数值、日期和明确排除项仍适合控件。我的方案是先解析成用户看得懂的条件，再允许修改确认后执行。这样降低输入门槛，也避免模型误解一个关键条件，后面整批检索都跑偏。

追问1：解析错了怎么办？

追问提纲：高影响先确认 → 无损修改

粉丝上限、排除项这类关键条件执行前展示；明显冲突或缺失时先问清。修改后更新结构化条件，不让用户重新打一大段话，也不把“没填写”自动当成“不限制”。

追问2：哪些条件必须用控件？

追问提纲：可枚举 → 误解代价大

粉丝区间、时间范围、批次数量和明确开关优先用控件；内容风格和经历要求保留文本加样例。不是控件越多越好，而是用最低操作成本把关键约束确定下来。

Q14 | 为什么不把全部筛选和审核交给模型？

考察点：合理分工，兼顾质量、成本和可排错性。

记忆提纲：① 确定规则用代码 ② 语义理解用模型 ③ 高风险人确认 ④ 按错误调整分工

口语回答：因为这些判断需要的能力不同。粉丝超没超范围、达人是否重复，代码更稳定，也没必要花模型费用；判断内容是否符合某种经历或风格，模型更有优势。审核还要区分疑似风险和最终结论，关键内容由人复核。这样不仅省成本，也容易排错：究竟是条件设错、数据缺失，还是模型理解错，而不是所有问题都混在一段回答里。

追问1：规则和模型冲突怎么办？

追问提纲：硬约束不覆盖 → 语义规则看语境

用户明确的粉丝区间是硬约束，模型评分再高也不能覆盖。审核关键词则要看上下文，引用、否定与直接宣传不一样。命中可触发检查，但不能所有命中都直接判成违规。

追问2：什么时候调整边界？

追问提纲：错误分类 → 对照验证

规则误伤多、表达变化大时，让模型参与理解；模型在固定条件上反复出错，就补代码校验。调整后用原来的失败样本和独立测试样本一起检查，不只看修好了一个例子。

Q15 | 项目到底是 Workflow 还是 Agent？

考察点：解释执行设计及理由，不靠模块名包装。

记忆提纲：① 审核固定阶段 ② 检索按反馈调整 ③ 约束由代码控制 ④ 按需开放自主性

口语回答：我按任务特点分开设计。审核要检查素材、规则、证据和风险，阶段相对确定，用固定 Workflow 更容易保证覆盖和追溯。找达人会遇到数量不足、重复多、关键词效果差，需要按结果续搜或结束，适合做反馈循环。当前动作选择主要由代码策略控制，模型负责意图和内容判断。我的重点不是追求更自主，而是让系统在明确约束下完成任务，错误时知道在哪一步停下来。

追问1：Workflow 与 Agent 边界在哪？

追问提纲：谁决定下一步 → 自主程度

固定代码分支可以很复杂，也可以循环，但仍是预设控制；模型根据目标和观察自主选择下一步工具或路径，才体现更强的 Agent 自主性。两者可以混合，有循环不自动等于完整 ReAct。

追问2：为什么有 Planner 和 Skill？

追问提纲：组织计划 → 复用能力

Planner 组织执行计划，Skill 封装专项能力，便于复用和测试。计划也可以由代码生成，不能因为模块叫 Planner 就说有模型自主规划。职责分开，后续换策略时就不用重做每项能力。

Q16 | 为什么每批 20 人？不足怎么办？

考察点：数量、质量、等待与成本的取舍。

记忆提纲：① 复核负担 ② 等待与调用成本 ③ 不凑数 ④ 保存续检进度

口语回答：20 人是当前批量的产品取舍，不是技术只能取到这个数。批量越大，读取和判断越多，等待和复核负担也越大；太少又不够选择。因此先用 20 人作验证起点，观察采用和等待情况。不足时继续检索，但不能牺牲核心条件凑满；数据耗尽或服务受限，就返回真实结果和原因，保留进度，避免下次重新查一遍。

追问1：20 怎么验证？

追问提纲：比较批量 → 足量候选的总成本

比较不同批量下，拿到足够可用候选要多久、检查多少人、消耗多少接口成本。如果 10 人就够，20 人可能浪费；若多数任务要筛很多人，就考虑渐进交付和继续检索。

追问2：为什么不分页展示 50 人？

追问提纲：展示成本不等于处理成本

分页只解决页面放不放得下，不自动减少获取和分析 50 人的成本。可以测试边检索边交付，但不能只是分几页，就认为等待和人工负担消失了。

Q17 | 怎么让结果可解释、可追溯？

考察点：可解释性如何服务用户决策，而非展示一大段模型推理。

记忆提纲：① 展示判断证据 ② 定位原始内容 ③ 保存版本快照 ④ 支持纠错

口语回答：我希望解释能帮助用户决定“用不用这个结果”。达人结果要说明匹配了什么、哪些条件没满足，并能回到主页或内容；审核则展示风险原文、规则依据和修改理由。后台还要保存任务输入、规则和知识版本，方便复现争议。没必要把模型的整段推理展示出来，用户更需要可核实的证据和不确定项。有出处只是第一步，还要验证出处确实支持这个判断。

追问1：证据错了怎么办？

追问提纲：暂停确定结论 → 修正来源 → 回归

先把对应结果标成待确认，不继续用错误证据支撑结论。再分清原数据错、定位错还是模型曲解。修正后重跑相关项，并把这个例子放进回归集，避免只换一段解释。

追问2：引用正确率怎么算？

追问提纲：固定分母 → 存在、定位、支持

以抽检引用为单位，只有来源存在、定位正确、内容支持结论都满足，才计为正确。同时看重要结论有没有漏引；只统计已引用部分，可能掩盖关键结论根本没证据的问题。

Q18 | 怎么评估项目效果？

考察点：将业务价值、AI 质量与工程表现连起来。

记忆提纲：① 业务任务是否更好完成 ② 分阶段找原因 ③ 同质量比较总成本 ④ 线上线下联动

口语回答：我会分三层。业务层看可用名单是否更快交出、审核是否减少查证和返工；质量层看条件解析、候选相关性、审核漏报误报和引用；工程层看成功率、等待和单任务费用。比如系统搜得快但候选不合格，人工复核更久，不能算提效。评估要把等待、修改和整理都算进总任务成本，再用分阶段指标解释原因。本地 Eval 用来发现回归，真实用户任务用来证明业务价值，两者不能互相替代。

追问1：小样本全对为什么不能宣传？

追问提纲：覆盖偏差 → 调试泄漏 → 不确定性

可能只测了容易题，或者这些题已经参与调试。即使全对，也只能说明这批样本表现好，不能推成普遍准确率。我会同时报告数量、类型和测试条件，再扩到真实难例。

追问2：谁标注，分歧怎么办？

追问提纲：业务专家 → 独立判断 → 争议裁定

候选由熟悉任务的媒介判断，复杂审核找有审核经验的人。先写清标准，部分样本双人独立标注；分歧保留原因，再讨论适用条件。不是简单投票凑一致，而是把模糊规则明确下来。

Q19 | 项目当前取得什么结果？

考察点：能否把交付成果、初步价值和下一步验证分清。

记忆提纲：① 两条功能路径 ② 一天计时自测 ③ 准备上线阶段 ④ 下阶段验证采用

口语回答：目前的成果有两类。功能上，已完成找达人、候选管理和导出，以及图文辅助审核相关开发和内部验证。价值上，我亲自做过一天测试，20 人名单从原来约 3 小时缩短到 40—60 分钟，说明这个方向有继续验证的价值。项目还在备案、准备上线，接下来不是继续堆功能，而是让真实媒介带任务试用，验证候选采用和重复使用；审核也要独立测复核耗时与漏报，不能借用找人的提效结果。

追问1：跑通和稳定上线有什么区别？

追问提纲：一次成功 → 多条件可用 → 能恢复

跑通说明特定输入和环境能完成；稳定上线还要覆盖不同用户、数据源异常、并发和网络问题，失败后能恢复，并且有监控。一次成功不能证明持续服务能力。

追问2：内部验收有哪些边界？

追问提纲：版本与样本 → 业务结果另测

内部验收确认的是这版功能是否按规则工作，不能直接证明所有行业适用或用户愿意持续用。模型、规则或数据源变了，关键场景还要回归；业务价值需要真实使用另外验证。

Q20 | 准备怎么冷启动？

考察点：先找到能验证价值的人，而不是泛泛说做推广。

记忆提纲：① 同类媒介种子用户 ② 真实任务陪跑 ③ 首次完成与复用 ④ 有案例后推广

口语回答：我会先找正在做素人名单、愿意带真实任务来的媒介，而不是先追求注册量。第一批从朋友及她介绍的同行开始，陪他们完成一次任务，记录原流程、最终采用和没用上的原因。做成一次后，再看下一次类似任务会不会主动回来。等能够讲清“哪类需求、怎么用、结果怎样”，再在小红书分享真实案例引流。冷启动前期最重要的是缩短价值验证，不是把流量先灌进来。

追问1：首批用户从哪来？

追问提纲：现有关系 → 符合任务条件

先通过媒介朋友联系同行，但筛选条件是近期有真实需求、愿意反馈，而不只是认识我。后面用同场景的案例内容吸引陌生用户，逐步降低熟人样本的偏差。

追问2：朋友反馈会偏吗？

追问提纲：看行为 → 引入陌生样本

会。所以不只听“挺好”，更看有没有用真实任务、采用多少、下次还用不用。也要尽快引入不认识我的用户。熟人反馈适合发现明显问题，不能直接证明市场需求。

Q21 | 竞品和差异化是什么？

考察点：理解替代方案和选择理由，不拿技术名词当壁垒。

记忆提纲：① 平台与人工都是替代 ② 比完整任务成本 ③ 聚焦细分流程 ④ 验证差异是否成立

口语回答：我会比较两类替代：达人发现平台，以及人工搜索加表格的现有做法。真正要比的是同一份名单从需求到交付的总成本，包括数据覆盖、候选质量、复核和整理，而不只是有没有自然语言输入。媒介助手的切入点是个人媒介的工作流程，把需求理解、筛选、候选管理和图文初审衔接起来。这个差异要靠用户采用验证，Agent、RAG 本身不是壁垒。后续更值得积累的是业务标准、任务反馈和持续可用的数据能力。

追问1：平台也加自然语言搜索呢？

追问提纲：功能不再稀缺 → 比流程价值

那就不能把自然语言当差异化。要看我们是否在某类任务的采用率、复核时间和使用成本上更好；如果没有明确优势，就缩小场景，而不是继续增加一个相似功能。

追问2：为什么不用成熟平台？

追问提纲：尊重替代 → 验证未满足需求

如果成熟平台已经解决得好，用户就该用它。我的机会应来自它没有满足的需求，比如某类筛选标准或操作负担；这些必须通过访谈和同任务比较确认，不能预先假定对手贵或不好用。

Q22 | 数据读取不稳定或受限怎么办？

考察点：是否把数据依赖当作产品成立条件，能给替代路径。

记忆提纲：① 来源与权限 ② 错误分类 ③ 保存进度并透明降级 ④ 替代数据方式

口语回答：我会把数据能力作为产品前提管理。先确认来源、使用权限和覆盖，再把失败分成超时、限流、余额或权限不足。短暂错误可以有限重试，权限问题不能靠不断重试解决。用户侧要保留已有候选和进度，说明缺了什么、如何继续；长期无法稳定取数，就评估合规数据源或用户导入名单。审核处理用户上传素材，可以独立工作，不让找人故障把整个产品都锁住。

追问1：最终无法稳定合规取数，产品还有价值吗？

追问提纲：承认主假设失败 → 重新验证替代场景

自动找人的核心价值会受影响，不能继续承诺原来的效果。可以验证用户导入后的筛选管理或独立审核，但这是范围调整，需要重新看用户是否愿意用；不能靠保留一个界面维持项目。

追问2：有小红书官方授权吗？

追问提纲：直接回答 → 区分技术与许可

目前没有已确认的官方授权。项目有真实数据读取和第三方接口路径，但技术能调用不等于获得平台商业许可。正式对外提供服务前，必须把来源和使用范围核实清楚。

Q23 | 模型成本和延迟高，怎么优化？

考察点：按瓶颈优化，并算到用户任务而不是只算 Token。

记忆提纲：① 拆任务耗时与费用 ② 先减无效工作 ③ 按难度分模型 ④ 质量回归后放量

口语回答：先把一份任务拆成取数、检索、模型分析和后处理，找实际瓶颈。有时慢的是数据接口，不是模型。优化顺序上，先用代码过滤和去重，避免没必要的调用；再减少重复上下文，对可复用且不过期的数据做缓存；独立步骤考虑并行，难易任务分别路由。最终看每份合格名单或有效审核的总成本和 P95 等待时间。如果调用便宜了，却让人工返工增加，优化就没有成立。

追问1：先优化成本还是延迟？

追问提纲：看业务卡点 → 守住质量底线

若用户经常等不及退出，先处理等待；若完成率正常但每单成本超过可承受范围，就先降成本。两者都紧时先缩任务范围或渐进交付，而不是直接换最便宜的模型。

追问2：降级阈值怎么定？

追问提纲：用户容忍度 → 实测分布 → 明确结果状态

结合正常耗时分布和用户可接受的等待设时限，重试受总预算限制。超过后是返回部分结果、转异步还是人工处理，要按任务定。审核图片失败只能叫部分完成，不能降成纯文本却仍显示全量通过。

Q24 | 重做一次会改变什么？

考察点：复盘是否改变投入顺序，而不是只说多做调研。

记忆提纲：① 更早做真人任务 ② 缩到一个主任务 ③ 先立衡量口径 ④ 证据决定扩展

口语回答：我会更早把真实用户测试放进里程碑，并先缩到找达人这一个主任务。之前同时推进找人和审核，功能增长比用户验证快。重做时，第一轮先确认用户原来怎么筛、名单什么标准算可用，再做最小路径，让用户用一次；在这之前就记录人工基线和采用标准。只有确实减少总工作量，再扩候选管理和审核深度。这样每一轮投入都有上一次反馈支撑。

追问1：当时为什么没这样做？

追问提纲：开发惯性 → 认识结果差距

开发背景让我比较容易从需求直接进入实现，也想把整套流程证明可行。后来发现“功能做完”和“用户愿意反复用”之间还有距离，所以需要调整验证顺序。

追问2：最想验证什么假设？

追问提纲：同质量更省事 → 愿意再用

在候选质量不下降的前提下，真实媒介自己复核和整理后是否仍然省时间，并愿意下一次继续用。如果只是系统输出快、人工要全部重看，核心价值就还没证明。

Q25 | 介绍一下简历助手

考察点：小项目也能说明明确场景和产品判断。

记忆提纲：① 岗位匹配的准备负担 ② 事实与 JD 对齐 ③ 简历到面试衔接 ④ 本地自用

口语回答：简历助手解决的是投不同岗位时，简历表达和面试准备脱节的问题。输入已有经历和 JD 后，它帮助识别岗位重点，调整相关经历的表达，再生成可能被追问的内容。我的重点不是写得更夸张，而是让岗位要求、经历证据和面试说法对应起来：JD 要求某项能力，不代表用户就拥有它。这个项目是我从零设计开发、本地自用的小工具，主要用来验证这条准备流程。

追问1：为什么不一次 Prompt 生成？

追问提纲：事实核对与表达分离 → 定位错误

简单场景一次生成也可以，但事实缺失时容易把 JD 要求混进经历。分开做岗位分析、事实确认和表达，更容易发现哪里出了问题。是否分多次调用，要看质量提升是否值得额外等待，不是步骤越多越好。

追问2：怎么防止虚构？

追问提纲：事实表 → 缺项确认 → 输出核对

把公司、日期、职责、数据作为已确认事实单独保留；缺项就问，不让模型从 JD 补经历。输出后重点核对数字和贡献归属。表达可以润色，但每个成果都应该能在面试里用真实事情解释。

三 | 企业项目：体现需求分析和交付判断（Q26—Q33）

Q26 | 讲一个参与最深、最复杂的项目

考察点：复杂在哪里，你做了什么判断，最后交付了什么。

记忆提纲：① 母子公司资金计划 ② 三模块状态联动 ③ 正常、失败、延期分开 ④ 我的职责与运行结果

口语回答：我参与最深的是豪森药业资金管理项目，也去过现场。验收末期有一项需求：总公司要提前给多家子公司安排下季度每月的资金计划，子公司的外部应付账款会触发下拨和额度占用，超额要预警；当天没付出或付款失败，要上划资金并释放占用，延期账款当天不付。难点不是多做一个额度字段，而是人民币付款、资金计划、应收应付三个模块的状态必须对应。我承担需求澄清、流程与异常规则设计、开发联调，把正常、未支付、失败和延期分别讲清、落实到系统。这项功能已投入运行。它最能体现我的能力，是把复杂业务从口头要求变成各方都能执行和检查的流程。

追问1：最终谁做决策？

追问提纲：业务规则谁确认 → 方案由我澄清推进

涉及资金政策和客户业务口径，由客户及产品、项目负责人确认。我负责把可选方案、异常和影响讲清，推动确认并完成实现，不代替客户决定财务政策。

追问2：哪些是你独立负责的？

追问提纲：具体需求的完整责任 → 非整个项目

这项需求的澄清、流程和异常设计、开发联调由我承担，上线后期也单独承接需求开发。整个资金管理项目还有其他团队成员，我的贡献要落在这项需求上，不把所有模块都算给自己。

Q27 | 用业务语言解释资金计划需求

考察点：理解业务对象和约束，不陷入接口和数据库字段。

记忆提纲：① 计划是额度 ② 下拨是资金动作 ③ 付款决定后续处理 ④ 状态最终一致

口语回答：可以把它理解为总公司给每家子公司安排每月可用的资金计划。有账要付时，系统安排资金下拨并记录占用，超出计划就提醒。钱如果当天没有付出去，或者付款失败，要按规则上划并释放对应占用。这里有三件事：计划额度、资金实际在哪里、账款是否付成，不能混成一个状态。否则可能钱回来了，额度还占着；也可能额度释放了，钱却没回来。这个需求就是要让三者按业务规则保持一致。

追问1：为什么付款失败要释放额度？

追问提纲：未完成支出 → 避免虚占 → 与上划对应

按照这项业务约定，未完成的付款不能一直占着计划，否则后续可用额度会被低估。但释放必须与对应的资金和业务状态核对，不能收到一个失败通知就无条件加回额度。

追问2：上划和释放占用是同一件事吗？

追问提纲：资金转移 ≠ 额度记账

不是。上划是钱回到母公司，释放占用是计划可用额度恢复。两者要关联，但应分别记录完成状态，这样出问题时才知道该查资金动作还是额度记录。

备考备注：超额规则是预警，不改成自动禁止付款；延期只确认当天不付，具体拨款与占用时点需要回查，不能自行推断。

Q28 | 面对模糊需求，怎么澄清？

考察点：能把歧义转成可决策、可验收的具体问题。

记忆提纲：① 谁在什么场景遇到什么问题 ② 真实业务走一遍 ③ 分叉和异常 ④ 规则与验收确认

口语回答：我会先问目标，再拿一笔实际业务走完整流程。至少讲清谁发起、数据从哪来、什么时候触发、哪些条件影响结果，以及失败后谁处理。豪森这项需求里，重点就是把应付账款、下拨、付款和额度占用分开，再确认未支付、失败、延期的不同处理。最后把歧义整理成具体场景和预期结果，跟产品、客户确认，也让测试据此准备。这样确认的是同一件事，不是大家都说“理解了”。

追问1：举一个避免返工的例子？

追问提纲：延期是明确例外 → 提前进入设计和测试

延期账款就是一个必须提前说明的例外。如果只按“有应付就付款”理解，功能做完也不符合客户要求。我在这项需求里参与了延期等异常规则的澄清和设计，让它不是等上线才补的特殊情况。

追问2：客户和产品意见不一致怎么办？

追问提纲：同场景比较 → 分清决策权 → 留结论

用同一笔业务演示不同方案会造成什么结果，再区分是业务政策分歧，还是操作习惯分歧。政策由有权的人确认，技术影响由研发说明；确认后留下结论和验收标准，避免开发各自选一种理解。

Q29 | 异常规则和状态机怎么设计？

考察点：从正常流程走向可恢复、可审计的系统。

记忆提纲：① 分清业务对象 ② 事件触发状态转换 ③ 转换条件与动作 ④ 幂等、补偿、人工兜底

口语回答：先分清对象，再给每个对象列状态，而不是画一张什么都塞进去的大流程图。比如应付账款、付款任务、资金上划和额度占用可以关联，但状态各有含义。每次转换要写清触发事件、前置条件、执行动作和失败出口。重复通知、超时、乱序也要考虑：业务动作不能重复记账，处理中不能直接显示成功，自动恢复不了的要有人工处理入口。这样异常发生后，系统知道卡在哪、下一步由谁处理。

追问1：重复消息怎么处理？

追问提纲：业务幂等键 → 原子约束 → 回放不重复生效

我的设计会用业务单号、操作类型和必要版本标识同一个动作，由服务端用唯一约束或原子状态更新保证只生效一次。单纯“先查再写”在并发下仍可能重复，还要保留处理记录，方便重试和核对。

追问2：补偿失败怎么办？

追问提纲：异常可见 → 有限重试 → 人工恢复

保留失败原因、已完成动作和待恢复状态，区分可重试与必须人工处理的情况。有限重试仍失败就告警，提供对账线索和人工处理流程。补偿本身也要防重复，不能为了结束任务把它改成成功。

备考备注：本题是设计方法；豪森已确认做过程序与异常设计，但具体幂等键、事务和补偿实现未经本轮核验，不直接归为当时成果。

Q30 | 怎么推动跨团队协作？

考察点：不是联系人多，而是能否减少信息差、明确责任并解决阻塞。

记忆提纲：① 共同目标与验收 ② 依赖和负责人 ③ 阻塞及时升级 ④ 结论同步

口语回答：我会让协作围绕同一个交付结果展开。需求阶段先确认业务口径和边界；开发阶段明确接口、依赖和责任人；联调时用同一批场景检查；上线再和实施确认操作及异常处理。保融工作里，我实际对接过产品、测试、实施和客户，也在驻场时直接沟通。我的习惯是把“还差什么、谁确认、影响哪一步”说具体，不能只是群里发一句“麻烦看一下”，然后被动等回复。

追问1：讲一次冲突？

追问提纲：不编事件 → 用真实协调说明处理方式

我没有一个细节记得很完整、适合展开的激烈冲突案例。更有代表性的是豪森这类需求澄清：付款、上划和额度涉及不同模块，我负责把正常与例外情形摆出来，与产品和客户确认，减少不同理解进入开发。如果讨论资源冲突，我会把影响和优先级交给有权的负责人取舍。

追问2：没有汇报关系怎么推动别人？

追问提纲：共同影响 → 最小明确请求 → 负责人取舍

先说明对方这一步影响什么交付，提出具体、可完成的请求和时间。如果确实有更高优先级的工作，就协调负责人调整计划，而不是靠不停催促。协作不等于让所有人优先做我的事。

Q31 | 多个需求都很急，怎么排优先级？

考察点：能否给出排序原则和机会成本。

记忆提纲：① 风险与主流程 ② 截止期和影响范围 ③ 依赖与投入 ④ 明确被延期的工作

口语回答：我先分事故、交付阻塞和一般新增需求。资金或数据正确性问题优先看风险；再看是否卡住客户主流程、有没有不可移动的时间窗口、影响多少任务；最后比较投入、依赖和临时方案。比如付款主流程故障，通常比报表样式优化更急。但优先级不能只靠谁说得急，必须把插入一项会挤掉什么讲清楚，涉及跨项目资源时由负责人确认新的承诺。

追问1：销售要求插单呢？

追问提纲：核实承诺 → 列影响 → 重新排期

确认是否已经对客户承诺、真实截止时间和不做的损失，再让研发估最小范围。值得插单就同步哪些工作延期、谁通知相关方；不默认通过加班把所有承诺都保住。

追问2：如何拒绝需求？

追问提纲：认可问题 → 解释取舍 → 给替代或重评条件

我会说明当前不排的原因，以及用户可以怎样暂时完成工作，并约定什么条件变化后重新评估。拒绝的是本期投入，不是否认问题，也不只是说“研发没时间”。

Q32 | 临近上线客户改需求，怎么办？

考察点：范围控制和风险沟通，而不是一味答应或一味拒绝。

记忆提纲：① 判断变更性质 ② 评估连带影响 ③ 最小必要调整 ④ 重定验收和计划

口语回答：先判断这是缺陷、原需求没澄清，还是新增范围。缺陷和漏掉的核心规则不能简单按新增需求拒绝；真正新增则要评估对数据、接口、测试和上线窗口的影响。然后给可选方案：本期做最小必要部分、分期上线，或者顺延。确认后同步产品、研发、测试和实施，并更新验收。关键不是客户改不改，而是改动的成本和风险不能隐形。

追问1：客户坚持全部按时完成？

追问提纲：具体估算 → 提供选项 → 升级取舍

把需要的工作和关键依赖列出来，说明按原日期能交付什么，扩大范围需要什么条件。仍有冲突就请项目负责人共同沟通，不能先承诺一个做不到的计划，再把风险留到上线前。

追问2：你能自己承诺上线时间吗？

追问提纲：个人估算 → 联合确认 → 对外承诺

能估自己负责的工作，但完整上线还依赖联调、测试、实施和客户窗口。我会拿这些依赖一起确认，再由对应负责人对外承诺，而不是只按写完代码的时间算上线时间。

Q33 | 没有量化数据怎么证明价值？

考察点：用可核实的交付证据表达价值，不把没有数字等同没有成果。

记忆提纲：① 原业务要求 ② 落地机制 ③ 投入运行 ④ 下次补效果衡量

口语回答：我会把业务变化说具体。豪森这项需求把资金计划、应付触发、付款结果和异常处理落实到系统，功能已经投入运行。我承担了从澄清到联调的工作，能解释每种情况为什么这样处理，这是业务理解和交付的证据。没有记录的节省人力，我不报数字。如果重新做，我会在交付前定义异常处理耗时、人工干预次数和额度差异，后续就能判断不只是上线了，而是哪里改善了。

追问1：为什么当时没埋点？

追问提纲：职责与关注点 → 承认缺口 → 改进方法

当时职责以开发交付为主，重点在规则正确和验收，没有建立完整的业务效果基线。现在转产品，我会把衡量方式提前放进需求，而不是等上线后再想能提什么数字。

追问2：可以提供什么证据？

追问提纲：脱敏流程 → 职责范围 → 不泄露客户资料

可以讲脱敏后的业务流程、关键异常和我负责的部分，解释测试怎样覆盖。涉及任职可以提供相应证明；客户账户、合同和内部文档不会带出来，不能为了证明项目泄露资料。

四 | AI 基础：回答选型、边界与验证（Q34—Q43）

Q34 | RAG、Workflow、Agent 分别是什么？

考察点：能把概念放回架构，不将三者当成互斥技术。

记忆提纲：① RAG 补知识 ② Workflow 定流程 ③ Agent 选行动 ④ 三者可以组合

口语回答：它们解决的不是同一个层面的问题。RAG 解决模型回答时依据什么外部资料；Workflow 解决一项任务按什么预设步骤完成；Agent 更强调根据目标和执行反馈决定下一步行动。比如内容审核可以是固定 Workflow，其中先取相关规则供模型判断；开放式调查则可能让 Agent 动态决定继续查什么。先看缺的是知识、稳定流程还是动态决策，再决定组合，不能看到 AI 项目就把三个词都堆进去。〔来源1、3〕

追问1：RAG 为什么不等于知识库问答？

追问提纲：技术机制 → 多种业务输出

问答只是表现形式。审核可以检索规则后识别风险，报告生成可以检索资料后形成结论。共同点是外部知识参与生成或判断，而不是必须有聊天窗口。

追问2：举一个适合 Agent 的任务？

追问提纲：路径未知 → 反馈决定补查

围绕一个开放问题做资料研究。看完第一批结果，可能发现还缺价格或用户证据，需要选择补查方向。相反，按固定清单提字段，通常不需要这么大的自主空间。

Q35 | 如何设计并评估 RAG？

考察点：能分开检索问题和生成问题，知道怎样验证改动。

记忆提纲：① 知识治理 ② 相关召回与重排 ③ 有据生成 ④ 分层评测

口语回答：我会先定义要回答的业务问题和可用知识范围，处理文档时保留结构、来源、版本和权限。检索阶段根据问题找相关片段，需要时组合关键词与向量，再用重排减少噪声；生成阶段要求结论能对应资料，缺证据就说明缺口。评测也分开：相关内容有没有召回、排得够不够靠前，模型有没有忠实使用，以及最终用户能不能完成任务。如果资料没进上下文，继续改回答 Prompt 通常不是优先项。〔来源3〕

追问1：Chunk 大小怎么定？

追问提纲：业务语义完整 → 噪声与成本 → 用样本比较

先按内容结构切，不直接套一个字数。规则条款尽量保留适用条件和例外，必要时保留父级上下文。切太小会丢含义，太大会混入无关信息，用真实问题比较召回与答案质量后再定。

追问2：什么时候混合检索？

追问提纲：精确术语 + 同义表达 → 融合后验证

既有条款号、品牌名等精确匹配，又有用户不同说法时值得测试。关键词和向量各有优势，但分数不能直接随意相加，需要融合或重排，再看对漏检、延迟和成本的实际改善。

Q36 | 怎么控制幻觉？

考察点：不是背“加 RAG”，而是定位错误并控制对用户的影响。

记忆提纲：① 找错误来源 ② 给相关证据 ③ 校验重要结论 ④ 不确定时交接

口语回答：我会先分清错误来自哪里：资料没有或过期、检索没找到，还是模型看到了却推断过头。对应地做知识治理、检索优化和生成约束。重要字段用代码校验，事实结论要能回到原文；高风险结果让人复核，依据不足不强行下结论。像审核里，给出一个真实法条并不代表判断正确，还要看是否适用于这段内容。最后用错误样本检查风险是否减少，不能把加了 RAG 当成解决幻觉的证明。

追问1：有引用但不支持结论怎么办？

追问提纲：判为错误 → 取消确定结论 → 定位责任层

这是事实依据不成立，不算通过。先把相关结论转成待核实，再判断是资料选错还是模型曲解，分别修改检索或生成约束。引用数量增加，不能抵消引用质量差。

追问2：拒答率太高怎么办？

追问提纲：可答覆盖 → 部分回答 → 风险分级

检查问题是否本来可答、知识是否齐全、拒答规则是否过宽。可以先回答有依据的部分，再说明缺什么。低风险建议和高风险判断用不同策略，但不能为降低拒答率放开无依据结论。

Q37 | 怎么选模型？

考察点：任务评测、成本判断与上线风险，而不是熟悉多少品牌。

记忆提纲：① 必要能力与约束 ② 同任务盲测 ③ 质量过线后比成本 ④ 小范围验证

口语回答：先列必须满足的条件，比如中文图文理解、结构化输出、工具调用、数据使用要求和延迟预算。再用自己的典型任务、难例和失败案例做同条件比较，尽量让评审不知道来自哪个模型。质量达到要求后，比较总任务费用和稳定性；简单任务可以走更经济的模型，难例再升级。不能只看榜单或几次回答很顺就决定，更不能为了省钱，把成本转成更多人工返工。

追问1：贵模型只提升 2% 怎么办？

追问提纲：先定指标口径 → 看错误价值 → 算增量收益

先问是相对提升还是百分点、在哪些样本上提升。如果主要减少严重漏报，价值可能很高；若只是措辞更好，未必值得。再看增加的费用和等待，必要时只将高风险或难例路由给它。

追问2：模型升级怎么处理？

追问提纲：版本固定 → 回归与灰度 → 可回退

先跑固定测试集和历史失败案例，检查质量、格式、工具调用与耗时，再小范围试用。保留旧版本和配置，出现回归能回退。模型更新不应绕过产品验收。

Q38 | 怎么设计和管理 Prompt?

考察点：把业务标准变成可维护、可测试的指令。

记忆提纲：① 明确任务和边界 ② 定义输出契约 ③ 用正反例讲标准 ④ 版本化回归

口语回答：我会先把业务判断标准写清楚，再转成 Prompt。包括输入是什么、需要做哪些判断、不能做什么、输出哪些字段，以及资料不足怎么处理。模糊标准用正反例说明，比如“达人提供某项服务”和“达人本人有相关经历”不能混为一谈。固定规则、当前资料和用户输入分开组织；输出再用 Schema 和业务规则校验。每次改动记录版本，用同一组样本比较，不把写得长、写得专业当效果更好。

追问1：Few-shot 过拟合怎么办？

追问提纲：代表性示例 → 独立测试 → 看未见表达

示例覆盖不同表达和边界，但留出不参与调试的测试集。不能把每个失败答案都塞回 Prompt 再测原题；要看同一规则下的新表达是否也改善，必要时减少过于具体的示例。

追问2：Prompt 泄露怎么办？

追问提纲：不放秘密 → 权限在系统 → 限制外泄影响

Prompt 不应该存密钥，业务权限也不能靠模型保密来保障。即便提示词被看到，工具调用仍要经过服务端鉴权和参数校验。内部策略需要访问控制，但提示词保密不是核心安全边界。

Q39 | 什么时候 RAG，什么时候微调？

考察点：按问题类型选手段，理解成本和资料更新方式。

记忆提纲：① 缺知识用检索 ② 行为不稳评估微调 ③ 先做简单基线 ④ 数据与成本决定投入

口语回答：如果问题是业务知识经常更新、回答需要出处，我先考虑 RAG；如果知识给够了，模型仍不能稳定按特定格式或风格完成任务，再评估 Prompt、示例是否够用，是否值得微调。微调要有质量足够的训练数据和独立评测，也增加训练与维护成本，不是每个垂直场景都值得做。两者可以结合：检索提供新知识，微调改善任务行为。对媒介助手，优先把知识和判断标准组织好，比一开始训练模型更合理。

追问1：微调后知识过期怎么办？

追问提纲：实时事实外置 → 版本评测

需要更新和可追溯的事实仍从资料或工具读取，不能完全依赖参数记忆。如果业务行为也发生变化，再更新训练数据并回归。微调过不代表事实永远正确。

追问2：什么时候直接用长上下文？

追问提纲：资料少且范围明确 → 比质量与成本

资料量不大、权限清楚、一次任务范围明确，可以先把完整材料给模型，做一个简单基线。知识规模、噪声或成本上来后，再评估专门检索。能放得下不等于一定看得准，也需要测关键内容覆盖。

Q40 | 怎么建立 AI 产品评测体系？

考察点：评测如何服务迭代和发布决策。

记忆提纲：① 定义任务成功 ② 分层建数据集 ③ 匹配评分方式 ④ 回归门槛与错误分析

口语回答：先定义用户任务成功是什么，以及哪些错误不可接受。再从真实场景抽取正常、困难、边界和失败样本，保留独立测试集，并记录版本。确定答案用规则评分，主观质量由有业务经验的人制定标准，再考虑用校准过的模型辅助判分。报告不能只有一个总分，还要按错误类型、风险和任务阶段拆开。最后把评测变成发布门槛：这次修好了什么、有没有新增严重错误、等待和成本是否可接受。评测的用途是帮助决定能不能上线、下一步改哪里。

追问1：没有标准答案怎么办？

追问提纲：评分准则 → 锚点样例 → 独立评审

开放任务不一定有唯一文案，但可以有明确标准，比如必须覆盖哪些信息、哪些事实不能错、哪些风险必须识别。用好坏样例校准评审，再做分项打分或成对比较，不强求逐字一致。

追问2：离线变好，业务没变好呢？

追问提纲：指标代理失效 → 任务分布或流程问题

先检查测试样本是否代表真实任务，以及优化的指标是否影响用户价值。也可能结果更准了，但等待更长、操作更复杂。要回到任务漏斗和用户行为，不能继续盯着离线分数加模型能力。

Q41 | Agent 有哪些核心部分和常见失败？

考察点：对执行系统的理解，不只是“模型加工具”。

记忆提纲：① 目标与状态 ② 决策与工具 ③ 观察与结果校验 ④ 权限预算和退出

口语回答：我会把 Agent 看成一个受控执行系统。它需要明确目标和当前状态，能决定下一步、调用工具，拿到真实反馈后判断是否继续，并有权限、预算和退出机制。常见失败包括目标理解错、工具选错、参数错、重复执行，或者工具失败却继续编结果。产品要决定哪些步骤可以自主，哪些动作必须确认，还要让用户看得到进度和失败原因。只把工具接上，离可靠完成任务还有一段距离。

追问1：什么时候需要长期记忆？

追问提纲：跨任务稳定偏好 → 用户可控 → 不替代业务库

当用户确认过的偏好会影响后续任务时才考虑，例如长期关注的内容类型。已采用达人、任务进度这种准确业务事实应保存在数据库里。记忆要可查看、修改和删除，不能把一次随口表达永久当规则。

追问2：怎么避免无限循环？

追问提纲：硬上限 → 无进展检测 → 可恢复终止

步数、总时长和费用都设独立上限，系统层执行；连续拿不到新增信息或重复相同动作也要停。停止时返回已有结果和原因，保存可恢复状态，而不是只让模型自己判断“差不多该结束了”。

Q42 | 上下文和记忆怎么设计？

考察点：控制信息相关性、一致性、权限和成本。

记忆提纲：① 当前任务最小必要信息 ② 确认条件结构化 ③ 历史按需检索 ④ 记忆可更新可纠正

口语回答：我会先区分当前任务状态、外部知识和长期偏好，不把所有历史聊天直接堆进上下文。当前目标、已确认条件和关键证据优先保留；旧记录按需要读取，非关键内容可以摘要。金额、排除对象、任务已完成动作这类不能失真的信息，用结构化数据保存。长期偏好需要用户确认，还要有失效和纠正机制。上下文管理的目标是让模型拿到当前需要的信息，而不是给得越多越好。

追问1：摘要丢细节怎么办？

追问提纲：关键字段不压缩 → 保留来源 → 必要时回查

摘要只压缩叙述，不能取代重要原值。比如粉丝上限、用户明确排除的对象单独保留，摘要带原记录引用。判断依赖某个细节时重新读取，避免在不完整概括上继续推断。

追问2：用户前后矛盾怎么办？

追问提纲：识别冲突 → 明确确认 → 更新版本

区分明确改需求和表达含糊。明确修改时让新确认条件替代旧条件；影响结果较大的变化要再确认，并标记版本。不能把互相冲突的要求静默混在一起执行。

Q43 | AI 产品核心指标怎么设计？

考察点：指标服务目标，并能追到原因和代价。

记忆提纲：① 一个主目标 ② 质量护栏 ③ 过程诊断 ④ 分母与统计窗口

口语回答：先明确阶段目标。媒介助手早期主要看同质量名单是否更省事，所以总任务耗时和用户确认可用是关键；进入持续使用后再看复用和有效任务量。候选相关性、重复率、审核漏报误报是质量护栏，接口成功率、模型延迟和费用是诊断指标。每个指标都要明确分母、去重口径和时间范围，比如“采用率”是候选级还是任务级。这样数字变化时才能解释业务，而不是做出一张很好看的看板。

追问1：指标冲突怎么办？

追问提纲：先设不可突破的底线 → 再优化主目标

例如审核要省时，但不能以严重漏报增加为代价；名单要足量，但不能放弃核心条件。先设质量和风险底线，再在可接受范围里优化耗时和成本，而不是把所有指标随意平均成一个分数。

追问2：第一版阈值怎么定？

追问提纲：人工基线 → 错误成本 → 试运行修订

先测现有人工表现，再让业务判断哪些错误绝不能接受、哪些可以复核纠正，形成初始门槛。用试运行看分布后调整，不凭空写一个 95%。高风险错误还要单独统计，不能被大量简单成功稀释。

五 | 场景题：给出决策，不只列分析框架（Q44—Q50）

Q44 | 设计一个智能客服产品

考察点：能在模糊场景里定义范围、优先级和验证办法。

记忆提纲：① 限定售后场景 ② 查询先行、操作受控 ③ 知识与业务接口分工 ④ 转人工和解决率

口语回答：我先以电商售后为例，目标是减少重复咨询和等待，但不牺牲问题解决质量。先看历史咨询，把高频、规则明确的问题做第一版，比如退换货规则、物流和订单状态。规则从知识库取，订单事实查业务接口；真正退款需要身份、权限和业务条件校验，不能只凭模型对话执行。用户不满、事实冲突或系统无法处理时，带着摘要和操作记录转人工。先灰度看有效解决率、重复咨询率、满意度和单次服务成本，再决定扩大场景。

追问1：自助解决率怎么定义？

追问提纲：明确解决证据 → 观察重复联系 → 固定分母

分母是约定范围内进入 AI 服务的问题任务；分子要求有用户确认或业务状态证明解决，并在约定窗口内没有同问题重复联系。没转人工、用户退出都不能直接算解决，具体窗口按售后周期确定。

追问2：知识怎么保持更新？

追问提纲：责任人 → 生效失效 → 发布测试

每类知识有业务负责人和生效范围，政策发布同步更新，旧版失效但留历史。更新前用典型问法回归，重点测新旧政策交界，不让模型同时拿到两版互相冲突的规则。

Q45 | AI 功能使用率低，怎么分析？

考察点：定位流失阶段，再选措施，而不是上来加入口。

记忆提纲：① 分清没看到还是没再用 ② 看有效任务漏斗 ③ 分群与访谈 ④ 针对原因验证

口语回答：先把使用率拆开：目标用户有没有看到入口、有没有开始、任务有没有完成、之后有没有再用。没看到是触达问题；开始后放弃，可能是输入门槛、等待或结果不可信；做完仍不回来，要看任务频率和实际价值。再按新老用户、任务类型和结果质量分组，结合录屏或访谈找原因。比如名单生成成功但全要人工重筛，改入口没用，应该先修匹配质量。每次只针对主要原因验证一个改动。

追问1：优先看哪三个事件？

追问提纲：曝光 → 有效提交 → 用户确认完成

目标用户的入口曝光、有效任务提交、用户确认完成，并且要能关联同一用户和任务。后续结合时间看复用，不能把点击开始当任务完成，也不能让技术重试多计一次使用。

追问2：怎么判断伪需求？

追问提纲：排除体验问题 → 看真实行为 → 分清低频价值

用户知道怎么用，结果也达到约定质量，却仍不愿把真实任务交给它，现有办法又足够好，就要怀疑需求强度。不能只看 DAU，低频但省很多工作也可能有价值；关键是任务发生时用户会不会选择它。

Q46 | AI 功能怎么排优先级？

考察点：业务收益与 AI 可行性共同决定投入。

记忆提纲：① 痛点强度和覆盖 ② AI 增量收益 ③ 数据与实现可行性 ④ 风险和验证成本

口语回答：我会先看问题有多重要、多频繁，现有办法哪里不够，再判断 AI 能提供多少增量，而不是先看哪个功能最像 AI。还要检查数据是否具备、错误代价、投入和维护成本。高价值但不确定的场景先做小验证；规则就能稳定解决的，不必上 Agent。比如达人数据是否可得，是先于复杂推荐界面的验证项。优先级的结论应包括先做什么、暂不做什么，以及什么证据会改变这个排序。

追问1：老板坚持低价值 AI 功能怎么办？

追问提纲：理解真实目标 → 限定试验 → 约定退出

先问老板想验证销售机会、用户需求还是技术方向。如果确实值得低成本试验，就限定用户、投入和时间，提前约定继续或停止的标准；不能只因为我暂时看不到价值就否定，也不能无限投入。

追问2：能不能用 RICE 打分？

追问提纲：统一讨论语言 → 估计不是事实

可以按覆盖、影响、信心和投入辅助比较，但早期很多分值是估计。我会写明依据，把高影响、低信心的部分优先验证。分数帮助讨论，不代替对依赖、风险和战略目标的判断。

Q47 | 怎么给 AI 功能做 A/B 测试？

考察点：明确假设、随机化、指标和实验有效性。

记忆提纲：① 一个可证伪假设 ② 稳定分组 ③ 主指标与质量护栏 ④ 样本和决策预设

口语回答：假设我们想验证“执行前确认结构化条件能减少返工”，就把用户稳定随机分到有确认页和原流程两组，其他条件尽量一致。主指标看首次满足要求的任务完成率，护栏看放弃率、总耗时和错误条件占比。实验前确定适用人群、最小有意义变化、样本和持续周期，避免看到某天好就提前宣布成功。结束后既看差异是否可靠，也看提升是否值得新增一步操作。AI 输出有波动，但随机分组和足够样本可以比较总体效果。

追问1：样本不足怎么办？

追问提纲：不强做显著性 → 配对任务与定性验证

先做同类任务配对测试和任务观察，交叉安排使用顺序，减少熟练度影响。小样本用于发现大问题和估计变化范围，不包装成统计显著。等使用量足够再做正式随机实验。

追问2：模型随机性怎么控制？

追问提纲：冻结非实验变量 → 重复观察 → 保留版本

如果测交互，就尽量固定模型版本、Prompt、参数和知识条件；如果测模型，就把模型作为唯一主要变化。记录版本并覆盖足够任务，必要时对离线样本重复跑。低温度不等于每次完全一致。

Q48 | 用户说要 AI，但规则就能解决怎么办？

考察点：不把用户指定的技术误当作真实需求。

记忆提纲：① 问想改善什么 ② 建立简单基线 ③ 仅在必要处用 AI ④ 用任务效果沟通

口语回答：我会先问他想少做哪一步、现在为什么做不好。若是固定条件过滤和重复操作，规则更稳定；若只是输入表达复杂，可以用模型理解需求，后续由代码执行。比如“粉丝在某区间”不需要模型推理，“内容像真实分享”才需要更强的语义判断。我的责任是选最合适的方案，而不是满足一个 AI 标签。只要同样的任务更省事、更可靠，简单方案也能成立。

追问1：怎么和老板解释？

追问提纲：同任务演示 → 效果成本对照

用同一个任务比较规则、模型和混合方案，展示准确性、等待、费用和维护差异。讨论围绕用户结果，不围绕哪种技术更先进；若 AI 只在入口有价值，就只用在入口。

追问2：混合方案怎么设计？

追问提纲：模型提理解 → 代码验约束 → 人确认高风险

模型先把自然语言转成结构化条件，代码校验区间和必填项，再执行检索、去重。模型补充内容匹配理由，人工做最后采用。每一步都有明确输入输出，错误也容易定位。

Q49 | 数据隐私和安全怎么处理？

考察点：从数据流识别风险，不用“加密了”概括全部安全。

记忆提纲：① 最少必要数据 ② 权限与用户隔离 ③ 外部模型及工具边界 ④ 留存、日志和删除

口语回答：我会先画清楚数据从用户到服务端、模型和第三方接口的流向，判断每一步是否真的需要这些数据。业务数据按用户隔离，密钥只由服务端受控使用，访问和写入都校验权限。送给模型的私有资料要明确使用范围，日志尽量留任务号和脱敏信息；保留多久、怎么删除、异常谁处理也要有规则。加密只是其中一层，还需要验证跨用户访问、工具越权和恶意输入等场景。

追问1：调试日志与隐私怎么平衡？

追问提纲：可排错的最小记录 → 限权与期限

优先记录版本、任务状态、错误码和脱敏摘要。确实需要原始素材排错时，限制查看权限和保留时间，不把密钥或完整私有资料长期写进日志。调试方便不能成为无限收集的理由。

追问2：怎么防 Prompt Injection？

追问提纲：材料不当指令 → 最小工具权限 → 独立校验

网页、图片里的文字和知识库内容都是待分析材料，不能改变系统权限。工具只开放必要能力，服务端校验参数、用户和操作范围；高风险动作需要确认，并用恶意样本测试。单靠提示模型“不要被骗”不够。

Q50 | 与研发或算法有分歧怎么办？

考察点：把立场争论转成共同的决策问题。

记忆提纲：① 明确争议变量 ② 对齐验收标准 ③ 用样本和估算比较 ④ 负责人决策并复盘

口语回答：先把分歧具体化。业务说效果差，是召回不够、错误太多，还是等待太久？研发说成本高，是模型费用、数据依赖还是维护投入？双方先认可同一组样本和验收标准，再比较方案效果、投入和风险。能通过小实验解决的，不靠职位争论；涉及范围与资源取舍，由对应负责人决策。我有开发背景，可以帮助解释实现代价，但也要坚持把用户必须达到的结果讲清楚。

追问1：技术说做不了，业务必须上线？

追问提纲：区分做不了与不能按期 → 缩范围或人工辅助

先问是基础能力不具备，还是当前时间和资源不够。后者可以缩范围或分期，前者需要替代路径或人工辅助。如果关键质量无法保证，就明确风险、升级决策，不用“先上线再说”掩盖问题。

追问2：你有开发背景，会不会越过研发设计？

追问提纲：产品定目标约束 → 研发定实现 → 共同验证

我会给思路，但不把自己的实现当唯一答案。产品负责用户问题、优先级和验收，研发负责实现和稳定性判断；技术理解应该让比较方案更高效，而不是让我替团队单方面下结论。

六 | 实现深挖：把技术说到产品价值上（Q51—Q56）

Q51 | 你说的 Skill 具体是什么，和 Tool 有什么区别？

考察点：能解释复用单元、调用边界和维护价值。

记忆提纲：① Tool 提供操作 ② Skill 组织任务方法 ③ 输入输出和失败边界 ④ 复用与独立评测

口语回答：Tool 更像一项具体操作，比如查询达人接口、读取资料或保存结果；Skill 是完成一类任务的方法和能力封装，可以包含指令、规则、示例和工具使用方式。在媒介助手里，我按需求解析、图片理解、风险识别和证据关联等职责拆分，明确输入输出和失败处理。这样修改审核标准时，不必把整条流程重写，也容易单独评测哪一段出了问题。这里指自建业务 Skill，不代表它天然符合某个外部文件规范。〔来源2〕

追问1：拆这么多 Skill，是不是每一步都调模型，成本很高？

追问提纲：逻辑拆分不等于调用拆分 → 比总成本

不是。确定性任务不必调用模型，相关判断也可以合并在一次调用里。Skill 拆分是为了职责清楚和复用，调用如何合并要看质量与延迟，不能一拆模块就增加一次模型费用。

追问2：MCP 和 Skill 又有什么关系，你实际用了 MCP 吗？

追问提纲：连接协议与任务方法分层 → 开发工具不等于运行架构

MCP 解决应用怎样连接外部工具和资源，Skill 更偏怎样完成某类任务，两者能组合。我的开发环境里使用工具的方式，与媒介助手运行时架构是两件事；不能因为开发时用过 MCP，就说产品全部通过 MCP 执行。

Q52 | 你的 Agent Loop 真正体现 ReAct 的地方在哪里？

考察点：理解反馈如何改变行动，并准确说明自主程度。

记忆提纲：① 明确目标 ② 行动获得观察 ③ 按结果调整 ④ 停止与权限保护

口语回答：ReAct 的关键不是把“思考”三个字打印出来，而是推理和行动交替，利用真实反馈调整下一步。找达人时，第一轮可能数量少、重复多或某类条件淘汰很多，系统据此判断继续查、扩关键词还是结束；不能预先假定搜一次就完成。我的项目借鉴了这个反馈循环，但当前不少动作由代码策略选择，模型主要负责意图与内容理解。产品上这样做，是让可约束先稳定下来，再评估哪里值得增加模型决策。〔来源4〕

追问1：不足 20 人，能不能偷偷放宽条件补足？

追问提纲：硬约束不能偷改 → 放宽可见且可确认

不能。用户明确的必要条件代表任务目标，不能为了数量好看改掉。可以提示哪个条件导致候选少，让用户决定是否调整；如果已有策略允许放宽次要条件，也要显示放宽项及依据，不能让用户误以为全都满足。

追问2：怎么防止循环失控或费用过高？

追问提纲：系统硬预算 → 无增益停止 → 部分结果可交付

将请求数、费用、轮次和总时长放在系统层控制，达到目标、无新增或供应商错误时停止。限制不能只是 Prompt 的一句要求。上线前还要检查实际配置和异常测试，避免代码有上限逻辑、配置却把它关掉。

Q53 | 多模态具体解决了什么，为什么不只做 OCR？

考察点：从信息缺口说明视觉能力的必要性。

记忆提纲：① 风险分布在图和文 ② OCR 识字、视觉理解画面 ③ 图文结合判断 ④ 低置信与缺图处理

口语回答：图文审核不能只看正文，因为关键信息可能在图片里的文字，也可能在画面与文案组合产生的含义中。OCR 主要解决识字，视觉模型能辅助理解画面、对象和图文关系。我的设计是先提取可观察信息，再结合规则判断风险，而不是直接让模型看图给“合规或不合规”。比如正文和图片表达条件不一致，要把具体位置展示给人核查。多模态的价值是减少信息遗漏，但图片看不清或未读到时，也必须明确说明。

追问1：图片没读到，但正文审核成功了，能不能显示通过？

追问提纲：覆盖不完整 → 部分完成 → 补审

不能显示整篇通过。应明确“正文已分析，图片未完成”，保留已检查的结果，提供重试、换图或人工处理。模型降级是工程动作，用户必须知道审核覆盖范围发生了变化。

追问2：图片和文案矛盾，听谁的？

追问提纲：不擅自裁定事实 → 指出冲突 → 人工核对

不能默认文字或图片一定正确。先列出两边的具体内容和冲突，让用户核对原材料；如果图片模糊，还要区分是真冲突还是识别不确定。系统帮助发现问题，不凭空替用户补一个一致的事实。

Q54 | 你的 RAG 到底做到了哪一步？

考察点：既能准确说明当前实现，也能提出有依据的下一步。

记忆提纲：① 入库与知识范围 ② 知识增强审核和引用 ③ 召回能力尚需完善 ④ 用漏检样本驱动升级

口语回答：目前主要完成了知识入库、用户和知识库范围筛选、规则关联，以及把知识片段提供给审核并保留引用。它首先解决的是审核有依据、能追溯。当前取资料的方式还比较直接，部分片段按范围加载后进入上下文，不是成熟的向量召回加重排链路。下一步我会先收集“应该找到却没找到”的规则样本，建立检索评测，再比较关键词、向量与混合方式。这样升级是为了解决实际漏检，不是为了简历里多写一个技术词。

追问1：知识量大了，直接取前面的片段有什么问题？

追问提纲：位置不等于相关 → 关键内容可能没进入 → 按问题召回

相关规则可能排在后面，模型根本看不到；前面的无关资料又占了上下文。应该根据当前素材和风险主题召回相关片段，并检查必要规则覆盖。先把需要的证据送进去，再谈生成效果。

追问2：结果带了法条引用，是不是就可信了？

追问提纲：来源真实 → 条件适用 → 结论被支持

不是。还要确认条款版本、适用对象和上下文，判断这段原文是否真的支持结论。当前引用定位是可追溯基础，不是法律判断正确的保证；资料不足要保留待核实状态。

Q55 | 你搭建的 Eval 怎么运行，评分有什么局限？

考察点：能讲出评测输入、执行、判分和迭代用途。

记忆提纲：① 按任务建用例 ② Runner 执行留版本 ③ 不同结果不同评分 ④ 错误分类驱动迭代

口语回答：本地 Eval 按规则解析、审核规则和语义匹配分用例，由 Runner 读取输入、执行并比较预期和输出。确定性字段适合精确匹配，开放判断需要明确评分准则和人工校准，不能一把尺子量所有任务。它现在主要帮助我在改 Prompt 或规则后发现回归，真实 Worker 主流程也有评测入口。接下来要补的是更有代表性的业务标注和独立测试集，让报告不只是“通过几题”，而是能指出哪类用户任务仍不可靠。

追问1：你说的相似度评分，就是语义相似度吗？

追问提纲：当前是字符相似 → 不能证明事实或语义正确

当前有一个评分器是字符二元组的余弦相似度，不是语义向量。它可以辅助检查文字接近程度，但一句话改了否定词，含义可能反过来，字面仍很接近。所以核心业务正确性要用字段、规则和人工标准检查。

追问2：怎么避免把测试分数做得很好看？

追问提纲：独立测试集 → 版本和失败都保留 → 分项报告

调试集和测试集分开，保留失败调用，不只统计成功返回的样本；模型、Prompt、知识和规则版本都记录。分别报告执行错误、质量错误和待评审。模型评分还要校准，不能让同一个模型自评后就认定质量过关。

备考备注：评测入口代码存在不等于最新生产全链路已执行；历史小样本通过率也不是当前 AI 总体准确率。被问到具体报告时，按能出示的版本和运行记录回答。

Q56 | 用户有多少？节省 66%—78% 的时间是怎么测的？

考察点：数据口径、因果意识，以及能否解释结果范围。

记忆提纲：① 准备上线、无正式规模结论 ② 一天本人自测 ③ 同任务耗时公式 ④ 补质量与样本记录

口语回答：项目还在备案、准备上线，所以目前没有正式运营的用户规模可以汇报。耗时来自我本人一天测试的观察：制作 20 人候选名单，从原来约 3 小时缩短到 40—60 分钟。以 180 分钟为基线，耗时减少约 66.7%—77.8%。这能说明流程自动化有潜力，但测试次数和同等质量的复核记录还要补齐。下一步会让真实媒介做同类任务，把等待、筛掉不合格候选和整理都算进去，看优势是否仍成立。

追问1：只有一天测试，面试官为什么相信？

追问提纲：限定能证明什么 → 给可复现验证办法

这一天不能证明稳定的平均提效，我把它作为初步信号。更可靠的方法是固定任务标准，保留人工与工具的过程、耗时和最终名单，让媒介独立复核，再做多份任务比较。没有完整记录的部分，不应报成精确统计结论。

追问2：上线以后怎样统计用户和审核效果？

追问提纲：用户分层去重 → 审核独立质量与耗时

注册按去重账号统计，剔除测试账号；完成真实任务算激活，再看后续任务周期的复用。审核单独准备经人工标注的图文，统计漏报、误报、引用和覆盖，再比较含查证、修改在内的总人工耗时。找人的节时不能拿来当审核结果。

备考备注：处理速度约为原来的 3—4.5 倍，与“耗时减少 66.7%—77.8%”分母不同。保留“耗时减少”最清楚。41 名历史落库达人不是注册用户；同类产品数据不替代你的结果。

七 | HR 与入职：诚实，但不要把答案说成自我否定（Q57—Q64）

Q57 | 为什么离职？中间几个月做了什么，会不会再转方向？

考察点：离职逻辑、选择成熟度和稳定性。

记忆提纲：① 职业方向差异 ② 如实解释短期尝试 ③ 用项目验证转岗 ④ 新岗位职责先对齐

口语回答：主要是长期发展方向有差异。我希望更多参与业务分析和产品决策，公司给我的路径更偏技术深耕，所以选择离开。之后 4 到 7 月跟亲戚做过一段金融相关业务尝试，7 月底开始系统学习 AI 产品，并独立推进媒介助手。这个过程也让我意识到，做职业选择应该先验证实际工作，而不是只看方向。现在我已经用项目接触了需求、方案、评测和交付，这次会重点确认岗位职责，希望在 AI 应用产品上持续积累。

追问1：是不是因为怕被 AI 替代才不做开发？

追问提纲：承认曾有焦虑 → 认识改变 → 用行动支持方向

当时确实有这个焦虑，AI 编程工具也影响了我的判断。但自己用 AI 做项目以后，我更清楚换岗位不能回避变化，产品同样要证明价值。现在转岗的依据是我更愿意承担问题定义和业务取舍，而不是认为产品经理不会被替代。

追问2：你说想往管理发展，是不是不愿意做基础工作？

追问提纲：先业务能力 → 接受具体模块 → 管理非当前诉求

不是，我现在首先想补的是业务和产品能力，不要求带团队。调研、写需求、整理反馈、跟测试都愿意做。只有先把具体模块做好、判断经得起结果检验，才谈得上更大的管理责任。

备考备注：首次问离职，优先讲职业方向；追问到 AI 焦虑时如实回答，不需要主动把所有负面情绪展开。不要贬低领导，不把短期金融尝试说成完整 AI 学习期。

Q58 | 你期望多少薪资，怎么确定的？

考察点：期望是否清楚，是否理解总包和岗位匹配。

记忆提纲：① 明确 16K—20K ② 基于职责与能力 ③ 确认发薪结构 ④ 保留合理协商

口语回答：我目前期望税前月薪 16K—20K，具体可以结合岗位职责和全年薪酬结构讨论。我的优势是企业业务理解、开发交付和 AI 应用独立实践，希望应聘的是能真正负责需求、方案和后续效果的产品岗位。如果双方匹配，我愿意综合看职级、固定发薪月数和奖金安排。也想了解一下这个岗位的预算范围和对入职前三个月的预期。

追问1：只能给 14K，能接受吗？

追问提纲：不立即承诺 → 看保证年薪与职责 → 明确再答复

14K 低于我目前的期望，但我愿意先了解完整条件，比如固定多少薪、奖金怎么发、试用期是否打折，以及实际负责什么。如果职责和成长路径很匹配，我会综合评估，再给您明确答复。

追问2：上一份工资和其他 Offer 是多少？

追问提纲：真实结构 → 真实进度 → 回到新岗位价值

上一份固定税前月薪是 [填写]，奖金是 [填写实际发放情况]；目前其他面试进度是 [填写]。新岗位的期望主要结合上海的岗位职责和我的匹配度提出，不只是按原工资加一个比例，希望双方按实际工作范围讨论。

备考备注：16K—20K 是 9 月 7 日结合公开岗位样本给出的谈薪建议，不是上海市场均价或录用承诺，本轮不重新做薪酬调查。14K—18K 可重点评估，高匹配岗位可尝试更高；你的实际底线需结合现金流决定，不必主动告诉 HR。出处见附录。原薪资和 Offer 不代填。

Q59 | 入职前三个月你准备怎么做？

考察点：先理解业务，再通过可交付结果建立信任。

记忆提纲：① 30 天摸清任务与基线 ② 60 天验证一个改进 ③ 90 天复盘结果 ④ 目标与负责人对齐

口语回答：第一个月先跟业务和用户走真实任务，了解现有产品、数据、协作方式和主要问题，选一个范围明确的改进并建立基线。第二个月推进方案验证和交付，跟研发、测试确认质量门槛；第三个月看真实使用结果，决定继续扩大还是调整。每个阶段都应该有具体产出，比如问题清单、可评审方案、验收记录和效果复盘，而不是只说熟悉业务。时间会按项目周期调整，我会先和负责人对齐预期。

追问1：接手的是存量产品，没有从零项目呢？

追问提纲：存量失败点 → 小改动验证

从高频失败和返工多的步骤切入，结合日志、客服反馈和任务观察找问题。先做可衡量的小改动，证明改善再扩大；没有从零机会不影响做出产品价值。

追问2：试用期怎么证明你是产品，不是开发支援？

追问提纲：职责先确认 → 产品决策和效果作为交付

入职时就对齐负责的用户问题、需求范围和验收指标。可以写原型代码辅助验证，但主要成果应是有依据的方案、推动完成的功能和复盘结果，而不是临时接了多少开发任务。

Q60 | 讲一个你做得不够好的地方，以及怎么改？

考察点：真实反思、责任承担和行动变化。

记忆提纲：① 功能先于用户验证 ② 开发惯性造成范围扩大 ③ 验证提前进排期 ④ 看实际改变

口语回答：媒介助手里，我比较早就同时推进找人和审核，希望做出完整工具，但真实用户验证没有同步跟上。这是我的判断问题，不只是资源少：我沿用了“先把功能做完”的开发习惯。后来做计时自测和评测时，发现功能可用、结果可靠、用户愿意复用是不同的事。所以接下来每个迭代会先写清谁来试、带什么任务、达到什么结果才继续，而不是把调研留到全部开发完之后。

追问1：这只是反思，有实际改变吗？

追问提纲：已有行动 → 尚未完成的验证分开

已经做过一天名单计时自测，也建立了本地评测入口，开始按结果检查，而不只看功能是否运行。真实用户的复用验证还没完成，这会是上线后的优先工作，不能说已经完全解决了。

追问2：如果用户试完觉得没用，你能接受停掉吗？

追问提纲：定位失败原因 → 有限修正 → 不成立则停

能。先分清结果质量、操作负担还是需求本身的问题。前两类可以限定投入修正；若质量和体验达到标准，用户仍不愿在真实工作里用，就该缩范围或停止，不因为已经写了很多代码继续投入。

Q61 | 媒介助手怎么商业化，免费用户怎么转付费？

考察点：理解价值、使用频率与单位经济，而不是先做会员页。

记忆提纲：① 谁因什么付费 ② 重复价值先成立 ③ 套餐与任务量匹配 ④ 收入覆盖可变成本

口语回答：先确认谁有持续任务、谁为这段工作买单。个人媒介可能更关心一份可用名单省了多少时间，团队还会看交付和协作。早期先验证真实任务和复用，再用明确的额度、价格和服务范围测试付费。低频任务可以测试按次，高频可以测试套餐，但要看数据接口和模型成本是否可覆盖。免费体验应让用户看到完整价值，同时控制成本；不能把注册量直接当成商业化基础。

追问1：怎么知道用户是真愿意付费，不是客气？

追问提纲：真实任务后 → 明确价格范围 → 看购买行为

让用户完成真实任务后，提供明确价格、额度和限制，看是否进入实际付费试用。访谈里说愿意，只算意向；付费后有没有持续使用和续费，才进一步说明价值稳定。

追问2：怎样判断这个业务赚不赚钱？

追问提纲：单任务贡献 → 获客与留存 → 固定成本

先算每个付费任务的收入减可变成本，包括数据接口、模型、图片处理、失败重试和人工支持。再看客户留存、获客成本与回收周期，最后覆盖研发等固定投入。只算 Token 费用，容易把真实成本低估。

Q62 | 内容审核为什么值得做？你怎么判断它真的有用？

考察点：讲清审核独立价值、人机分工和质量取舍。

记忆提纲：① 图文查证负担 ② 定位风险与依据 ③ 人工确认而非自动裁决 ④ 漏报误报与复核耗时

口语回答：审核要解决的是媒介查资料、找风险位置和反复改稿的负担，不是再做一个能聊天的窗口。方案上，把图文内容、选定规则、风险位置和修改理由放在一起，让人工复核有依据。是否有价值，要看人工完成同质量审核的总时间是否下降，同时严重漏报和误报是否在可接受范围。仅仅多报几条风险不算更好，可能让用户查得更久。因此我定位成合规辅助初审，复杂和高风险内容仍由有经验的人确认。

追问1：漏报和误报哪个更重要？

追问提纲：按风险分层 → 高风险优先召回 → 控制误报负担

高风险场景优先控制漏报，但误报太多会让人忽视提示，所以要同时看召回率和精确率。召回是实际风险找到了多少，精确率是报出的风险有多少成立。不同风险分别定门槛，不能只看整体准确率。

追问2：不用人工，能不能直接自动改好并发布？

追问提纲：修改可能改变事实 → 对照确认 → 不自动发布

现阶段不合适。改写可能改变宣传事实、证据条件或品牌意思，需要保留原文与修改对照，由人确认。资料不足时应提示补证据，不能编一句听上去安全但不真实的话，更不能直接自动发布。

Q63 | 你会写 PRD、画 Figma，怎么证明不是会用工具而已？

考察点：产物能否支持讨论、实现、测试和结果验证。

记忆提纲：① 解释用户问题 ② 说明方案取舍 ③ 状态与异常完整 ④ 原型规则验收一致

口语回答：我会拿一条具体需求展开，而不是展示很多页面。比如检索不足时，用户需要知道是条件太严、数据耗尽还是服务失败，不同原因决定能做什么操作。PRD 要写清触发条件、状态、可恢复方式和验收；Figma 要让用户看得懂这些状态，研发和测试也能对上。如果页面只有正常流程，规则和异常全靠口头补充，就算工具熟练也不算产品设计完成。我的重点是让材料能帮助团队做同一个东西。

追问1：给一个可验收的例子？

追问提纲：给定条件 → 触发事件 → 可观察结果

例如目标 20 人、已有 12 人时接口受限：页面显示真实数量和受限原因，已有结果不丢；恢复后沿进度继续，不能重复加入旧候选，也不能未经允许修改必要条件。这些都能分别构造测试，而不是只写“体验流畅”。

追问2：需求没说清，研发已经开工怎么办？

追问提纲：锁定当前假设 → 优先澄清高影响 → 同步变更

先问研发按什么假设实现，尽快确认影响数据和主流程的歧义；暂时无法决定的划出范围，必要时暂停相关部分。确认后同步原型、规则和测试，避免只口头改一处，其他人还按旧理解推进。

Q64 | 代码由 Codex 写，你自己的价值是什么？

考察点：产品判断与交付责任是否由你承担，能否解释真实贡献。

记忆提纲：① 定义问题与范围 ② 决定业务分工 ③ 验证而非照单全收 ④ 对结果负责

口语回答：AI 帮助我提高实现速度，但不会替我承担产品判断。我需要决定为谁解决什么问题、哪些功能先做、哪些条件不能放宽，以及什么结果才算可用。比如找达人不是返回越多越好，审核也不是给一个“通过”就结束，这些边界要我来定义。代码生成后，还要检查数据、权限、异常和实际结果，再决定能不能交付。所以“独立完成”是我负责从需求到验证的全过程，不是宣称每行代码都手写。我的价值应该用决策和结果解释，而不是用提示词数量解释。

追问1：代码你都看得懂吗，出了问题能处理吗？

追问提纲：核心链路能解释 → 分层排错 → 不懂就验证

主要前后端业务链路是我熟悉的范围，出错会先按输入、接口、数据和状态逐层定位。新领域的实现会查资料、做最小测试，不只相信 AI 的解释。关键逻辑如果还不能解释和验证，就不能贸然交付。

追问2：AI 给了一个看似正确的产品方案，怎么判断？

追问提纲：事实是否成立 → 取舍是否合理 → 真实任务验证

先核对它依据的用户和数据是否真实，再看原流程、替代方案、异常和人工成本有没有漏。最后用原型或小功能跑真实任务。方案结构完整、术语多，只能说明写得像方案，不代表适合这个用户。

附录 | 记忆卡、事实边界与参考来源

先练这 12 题

Q01 自我介绍; Q02 转岗; Q09 媒介助手; Q11 北极星指标; Q18 效果评估; Q26 豪森需求; Q35 RAG; Q40 Eval; Q52 ReAct; Q56 数据口径; Q57 离职; Q64 AI 编程与个人贡献。

练法: 先遮住答案, 只看四个关键词讲一遍; 再看自己是否漏了判断和例子。第二轮只看问题, 录音回听。能把一个判断讲清楚, 比在一分钟内念完所有术语更重要。

同类题怎么避免答成一样

项目介绍 Q09: 讲用户、方案、你的贡献和结果, 不深入每个技术细节。项目结果 Q19: 先讲交付和自测, 别再从背景讲起。评估 Q18: 讲业务、质量、工程三层。指标 Q43: 讲主目标、护栏和统计口径。

RAG 概念 Q34: 回答它解决什么问题。RAG 设计 Q35: 讲知识、检索、生成和评测。当前实现 Q54: 只讲现状和下一步, 不能把 Q35 的理想方案说成已经完成。

Eval 方法 Q40: 讲怎样建立评测及发布决策。Eval 实现 Q55: 讲实际用例、Runner 和评分局限。离职 Q57: 先答职业方向, 具体追问再解释焦虑和短期尝试。

三个数字口径

年限: 2023.11.14—2026.03.31 约两年四个半月, 含实习; 2024.07 毕业, 正式转正日待确认。不要说三年正式产品经验。

耗时: 180 分钟降至 40—60 分钟, 耗时减少 66.7%—77.8%, 来自本人一天自测。测试次数、原始计时和同质量复核尚需补齐, 不能当作多人长期平均。

审核指标练习 (假设数据, 不是项目结果): 20 个实际风险, 系统报出 18 个, 其中 15 个成立, 则精确率为 $15/18 \approx 83.3\%$, 召回率为 $15/20 = 75\%$ 。必须先定义单位是素材还是风险项, 分母不能混用。

建议带到面试的证据

一段可演示的主任务; 一份脱敏 PRD 与对应原型; 一个真实失败及修正记录; 一次注明版本的 Eval 输出; 一天自测可回溯的记录。豪森用脱敏流程解释职责, 不展示客户账户、合同和内部材料。具体冲突、原薪资、Offer 或上线用户数没有事实就不代填。

技术与行情来源

以下资料只用于概念核对和补充阅读, 不代表个人项目按其完整实现。本轮重新查阅了所列技术资料; 薪资沿用 2026-09-07 的少量公开岗位参考, 不代表 2026-09-09 的全市场调查。题目按你的经历和目标选择, “高频” 不代表量化被问概率。

来源1: [Anthropic | Building effective agents](#): Workflow 与 Agent 的定义及选择边界。

来源2: [Anthropic | Equipping agents for the real world with Agent Skills](#): Skills 的组织与复用机制。

来源3: [Microsoft | RAG information retrieval](#): 检索环节、相关性与上下文组织。

来源4: [ReAct 论文](#): 推理、行动与观察交互; 代码反馈循环不自动等于完整论文实现。

来源5: [Model Context Protocol | Architecture](#): 工具和资源连接的协议分工。

薪资参考: [牛客 | 携程 AI 产品经理](#)、[BOSS 直聘 | 智慧树产品经理招聘列表](#)。9 月 7 日读取样本分别标注上海 1—3 年 10K—15K×12 薪、上海 AI 教育方向 1—3 年 15K—25K; 岗位职责不同, 不能直接求均值当作你的定价。

核对边界: 本轮基于原核准版、用户已确认经历、当前工作台与决策记录重写表达。未重跑付费外部接口、生产任务或用户计时; 未修改项目代码、简历和旧版 PDF。开发与方案能力得到体现, 不等于新增了尚未发生的业绩。